



Institut National des Postes et Télécommunications
DATA INE2

Rapport de Projet Deep Learning

Attaques Adversariales FGSM & PGD sur CNN
et Défense par Entraînement Adversarial

Projet :	Project 6 – Adversarial Robustness in Deep Learning
Réalisé par :	EL ASRI Mouad EL BAGHDADI Mohamed
Datasets :	MNIST, CIFAR-10
Notebook :	lien Colab – Code complet

Année scolaire 2025–2026

Table des matières

Résumé	2
1 Introduction	2
2 Jeux de données et modèles baseline	3
2.1 Datasets	3
2.2 Architectures CNN	3
2.3 Résultats baseline	3
3 Attaque FGSM	4
3.1 Principe	4
3.2 Résultats sur MNIST et CIFAR-10	4
4 Attaque PGD	5
4.1 Principe	5
4.2 Résultats sur MNIST et CIFAR-10	6
5 Comparaison FGSM vs PGD	6
6 Défense par entraînement adversarial PGD	7
6.1 Principe	7
6.2 Défense MNIST	7
6.3 Défense CIFAR-10	8
7 Évaluation finale : baseline vs modèle défendu	9
7.1 MNIST	9
7.2 CIFAR-10	9
8 Discussion et conclusion	10
8.1 Discussion	10
8.2 Conclusion	11

Résumé

Ce projet étudie la vulnérabilité de modèles CNN face aux attaques adversariales FGSM et PGD sur les datasets MNIST et CIFAR-10. L'objectif est d'analyser le comportement des modèles face à de petites perturbations adversariales, puis d'améliorer leur robustesse par entraînement adversarial.

Dans une première phase, deux modèles CNN baseline sont entraînés et sauvegardés. Le modèle MNIST atteint une précision propre de **99.50%**, tandis que le modèle CIFAR-10 atteint **92.98%**. Dans une deuxième phase, les modèles sont gelés et attaqués par FGSM puis PGD. Les résultats montrent que PGD est nettement plus destructrice que FGSM grâce à son caractère itératif et à la projection dans la boule de perturbation autorisée.

Dans une troisième phase, une défense par entraînement adversarial PGD est mise en place. Cette défense est très efficace sur MNIST : sous PGD avec $\epsilon = 0.15$, la précision passe de **8.12%** à **93.56%**. Sur CIFAR-10, les résultats sont plus nuancés : la défense améliore la robustesse contre les attaques PGD faibles ou modérées, mais introduit un compromis entre précision naturelle et robustesse adversariale.

Code source : <https://colab.research.google.com/drive/1CeORG2gpcNG1RAvY9KV5IwmSLr7Nvj9j>

1. Introduction

Les réseaux de neurones convolutionnels (CNN) obtiennent aujourd'hui d'excellentes performances en classification d'images. Cependant, ils peuvent être sensibles à de très petites perturbations ajoutées intentionnellement aux images d'entrée. Ces perturbations, souvent presque imperceptibles pour l'être humain, peuvent provoquer une mauvaise classification par le modèle. On parle alors d'**exemples adversariaux**.

Ce projet correspond au **Project 6 – Adversarial Robustness in Deep Learning**. L'idée centrale est d'analyser et d'améliorer la robustesse de modèles de deep learning face aux attaques adversariales. Les deux datasets utilisés sont :

- **MNIST** : images de chiffres manuscrits ;
- **CIFAR-10** : images RGB réparties en dix classes.

Deux attaques sont implémentées :

- **FGSM** : Fast Gradient Sign Method ;
- **PGD simplifiée** : Projected Gradient Descent avec un nombre fixe d'itérations.

Enfin, une défense par **entraînement adversarial** est appliquée. La démarche du projet suit donc les étapes suivantes :

1. entraînement des modèles CNN baseline ;

2. implémentation et évaluation de FGSM ;
3. implémentation et évaluation de PGD simplifiée ;
4. comparaison FGSM vs PGD ;
5. entraînement adversarial ;
6. analyse finale attaque vs défense.

2. Jeux de données et modèles baseline

2.1 Datasets

MNIST est composé d'images de chiffres manuscrits de taille 28×28 en niveaux de gris. Chaque image possède un seul canal :

$$x \in [0, 1]^{1 \times 28 \times 28}$$

Le dataset contient 10 classes correspondant aux chiffres de 0 à 9.

CIFAR-10 contient des images RGB de taille 32×32 :

$$x \in [0, 1]^{3 \times 32 \times 32}$$

Les dix classes sont : `airplane`, `automobile`, `bird`, `cat`, `deer`, `dog`, `frog`, `horse`, `ship`, `truck`. CIFAR-10 est plus difficile que MNIST car les images sont colorées, plus bruitées et plus variées.

2.2 Architectures CNN

Pour **MNIST**, le modèle utilisé est un CNN composé de couches convolutionnelles, BatchNorm, activation GELU, MaxPooling et Dropout. La partie convolutionnelle extrait les caractéristiques visuelles, puis un classifieur fully connected produit la sortie sur 10 classes.

Pour **CIFAR-10**, l'architecture est plus profonde et utilise des blocs résiduels avec connexions de saut. Ces blocs sont organisés en plusieurs stages, suivis d'un Global Average Pooling et d'une couche linéaire de classification. Cette architecture est plus adaptée aux images RGB complexes.

2.3 Résultats baseline

Après entraînement, les meilleurs modèles sauvegardés donnent les précisions suivantes sur les jeux de test :

TABLE 1 – Précision propre des modèles baseline

Dataset	Précision test propre
MNIST	99.50%
CIFAR-10	92.98%

Ces résultats montrent que les deux modèles baseline sont performants sur les images propres.




FIGURE 1 – Courbes d’entraînement du modèle baseline – MNIST




FIGURE 2 – Courbes d’entraînement du modèle baseline – CIFAR-10

3. Attaque FGSM

3.1 Principe

FGSM, pour *Fast Gradient Sign Method*, est une attaque adversariale rapide en une seule étape. Le modèle est gelé pendant l’attaque : ses poids ne sont pas modifiés. Seule l’image d’entrée est modifiée afin d’augmenter la loss de classification.

Soit x l’image originale, y la vraie classe, f_θ le modèle CNN, $J(\theta, x, y)$ la loss de classification et ϵ le budget maximal de perturbation. FGSM est définie par :

$$x_{adv} = \text{clip}(x + \epsilon \cdot \text{sign}(\nabla_x J(\theta, x, y)), 0, 1)$$

où clip garantit que les pixels restent dans l’intervalle $[0, 1]$.

3.2 Résultats sur MNIST et CIFAR-10

Le tableau suivant présente les résultats représentatifs obtenus avec FGSM. Les courbes associées contiennent l’ensemble des valeurs testées.

TABLE 2 – Accuracy et Attack Success Rate sous FGSM

MNIST			CIFAR-10		
ϵ	Accuracy	ASR	ϵ	Accuracy	ASR
0	99.50%	0.00%	0	92.98%	0.00%
0.05	96.79%	2.72%	2/255	61.22%	34.16%
0.10	70.47%	29.18%	4/255	54.96%	40.89%
0.15	27.53%	72.33%	8/255	46.99%	49.49%
0.20	13.31%	86.62%	16/255	28.74%	69.24%
0.30	9.66%	90.30%	—	—	—

On observe que la précision diminue lorsque ϵ augmente. Cela confirme que les modèles baseline, bien qu'efficaces sur images propres, sont vulnérables aux perturbations adversariales.




FIGURE 3 – Courbe de robustesse FGSM – MNIST




FIGURE 4 – Courbe de robustesse FGSM – CIFAR-10

4. Attaque PGD

4.1 Principe

PGD, pour *Projected Gradient Descent*, est une version itérative de FGSM. Dans ce projet, PGD est implémentée sous une forme simplifiée : un nombre fixe d'itérations est appliqué, avec une taille de pas α , puis une projection dans la boule ℓ_∞ de rayon ϵ autour de l'image originale.

Comme pour FGSM, les poids du modèle restent gelés pendant l'attaque. L'optimisation porte uniquement sur les pixels de l'image d'entrée. La mise à jour PGD est donnée par :

$$x^{t+1} = \Pi_{B_\epsilon(x)} (x^t + \alpha \cdot \text{sign}(\nabla_x J(\theta, x^t, y)))$$

avec la contrainte :

$$\|x_{adv} - x\|_\infty \leq \epsilon$$

La projection $\Pi_{B_\epsilon(x)}$ garantit que l'image adversariale reste dans le budget de perturbation autorisé.

4.2 Résultats sur MNIST et CIFAR-10

TABLE 3 – Accuracy et Attack Success Rate sous PGD

MNIST			CIFAR-10		
ϵ	Accuracy	ASR	ϵ	Accuracy	ASR
0	99.50%	0.00%	0	92.98%	0.00%
0.05	95.91%	3.61%	2/255	33.53%	63.94%
0.10	36.53%	63.29%	4/255	23.48%	74.75%
0.15	8.12%	91.84%	8/255	7.68%	91.74%
0.20	4.51%	95.47%	16/255	1.32%	98.59%
0.30	0.16%	99.84%	—	—	—

PGD est nettement plus destructrice que FGSM. Sur MNIST, à $\epsilon = 0.15$, la précision tombe à **8.12%**. Sur CIFAR-10, à $\epsilon = 8/255$, la précision tombe à **7.68%**.




FIGURE 5 – Courbe de robustesse PGD – MNIST




FIGURE 6 – Courbe de robustesse PGD – CIFAR-10

5. Comparaison FGSM vs PGD

PGD est systématiquement plus forte que FGSM sur les deux datasets. À $\epsilon = 0.10$ sur MNIST, FGSM conserve **70.47%** de précision contre seulement **36.53%** pour PGD. Sur CIFAR-10, à $\epsilon = 8/255$, FGSM conserve **46.99%** contre seulement **7.68%** pour PGD.

Cette différence s'explique par le caractère itératif de PGD. FGSM effectue une seule étape dans la direction du gradient, tandis que PGD recalcule le gradient à chaque itération et projette la perturbation dans la boule autorisée. Ainsi, PGD explore plus efficacement l'espace adversarial autour de l'image originale.




FIGURE 7 – Comparaison accuracy FGSM vs PGD – MNIST




FIGURE 8 – Comparaison accuracy FGSM vs PGD – CIFAR-10

6. Défense par entraînement adversarial PGD

6.1 Principe

La défense utilisée est l'**entraînement adversarial**. Le modèle est entraîné simultanément sur des images propres et des images adversariales générées par PGD pendant l'entraînement. La fonction objectif utilisée est :

$$L = \lambda \cdot \text{CE}(f(x), y) + (1 - \lambda) \cdot \text{CE}(f(x_{adv}), y)$$

où x est l'image propre, x_{adv} est l'image adversariale générée par PGD et λ équilibre la loss propre et la loss adversariale.

Cette défense est globale dans le cadre du projet : comme PGD est plus forte que FGSM, entraîner le modèle contre PGD permet ensuite de tester la robustesse contre FGSM et PGD.

6.2 Défense MNIST

Pour MNIST, les paramètres utilisés pendant l'entraînement défensif sont :

$$\epsilon = 0.10, \quad \alpha = 0.025, \quad \text{itérations} = 5$$

TABLE 4 – Résultats de l'entraînement défensif – MNIST

Epoch	Loss	Train clean	Train adv	Test clean
1	0.6006	99.17%	95.86%	99.41%
2	0.5737	99.31%	97.31%	99.49%
3	0.5643	99.42%	97.80%	99.51%
4	0.5582	99.54%	98.03%	99.51%
5	0.5554	99.55%	98.15%	99.51%

La précision adversariale d’entraînement augmente de **95.86%** à **98.15%**, tandis que la précision propre sur le test reste stable autour de **99.51%**. La défense MNIST est donc très efficace.

6.3 Défense CIFAR-10

Sur CIFAR-10, une première défense trop directe provoquait une baisse importante de la précision propre. Une version améliorée a donc été utilisée avec :

- curriculum progressif sur ϵ ;
- data augmentation ;
- pondération plus forte des images propres ;
- sauvegarde selon un score équilibré entre précision propre et robustesse.

TABLE 5 – Entraînement défensif avec curriculum – CIFAR-10

Epoch	ϵ	Test clean	Robust val	Score équilibré
1	2/255	90.99%	1.47%	46.23
2	4/255	90.28%	5.20%	47.74
3	6/255	88.21%	13.53%	50.87
4	8/255	86.69%	19.33%	53.01
5	8/255	86.29%	20.60%	53.45
6	8/255	86.36%	20.73%	53.55

Le score équilibré augmente de **46.23** à **53.55**, ce qui montre une amélioration progressive du compromis entre précision propre et robustesse. Cependant, CIFAR-10 reste plus difficile que MNIST.




FIGURE 9 – Entraînement défensif – MNIST




FIGURE 10 – Entraînement défensif – CIFAR-10

7. Évaluation finale : baseline vs modèle défendu

7.1 MNIST

La défense MNIST est très efficace. La précision propre reste presque inchangée :

$$99.50\% \rightarrow 99.51\%$$

Sous PGD à $\epsilon = 0.15$, la précision passe de **8.12%** à **93.56%**, soit un gain de **+85.44 points**.

TABLE 6 – Baseline vs défendu – MNIST sous FGSM et PGD

Sous FGSM			Sous PGD		
ϵ	Baseline	Défendu	ϵ	Baseline	Défendu
0	99.50%	99.51%	0	99.50%	99.51%
0.10	70.47%	98.10%	0.10	36.53%	97.52%
0.15	27.53%	96.84%	0.15	8.12%	93.56%
0.20	13.31%	95.31%	0.20	4.51%	77.63%
0.30	9.66%	89.29%	0.30	0.16%	2.42%




FIGURE 11 – Baseline vs modèle défendu – MNIST sous FGSM




FIGURE 12 – Baseline vs modèle défendu – MNIST sous PGD

7.2 CIFAR-10

Sur CIFAR-10, la défense est plus nuancée. La précision propre diminue :

$$92.98\% \rightarrow 86.36\%$$

ce qui correspond à une baisse de **6.62 points**. En revanche, la robustesse sous PGD faible ou modérée s'améliore clairement. À $\epsilon = 2/255$, la précision passe de **33.53%** à **66.32%**. À $\epsilon = 4/255$, elle passe de **23.48%** à **41.34%**.

TABLE 7 – Baseline vs défendu – CIFAR-10 sous FGSM et PGD

Sous FGSM			Sous PGD		
ϵ	Baseline	Défendu	ϵ	Baseline	Défendu
0	92.98%	86.36%	0	92.98%	86.36%
2/255	61.22%	67.55%	2/255	33.53%	66.32%
4/255	54.96%	48.61%	4/255	23.48%	41.34%
8/255	46.99%	25.85%	8/255	7.68%	10.37%
16/255	28.74%	9.10%	16/255	1.32%	0.25%

Sous FGSM, l'amélioration est limitée à faible perturbation. Sous PGD, la défense est bénéfique pour les attaques faibles à modérées, mais reste insuffisante pour les attaques fortes comme $\epsilon = 16/255$.




FIGURE 13 – Baseline vs modèle défendu – CIFAR-10 sous FGSM




FIGURE 14 – Baseline vs modèle défendu – CIFAR-10 sous PGD

8. Discussion et conclusion

8.1 Discussion

Les résultats obtenus mettent en évidence plusieurs points importants.

Premièrement, les modèles CNN entraînés sur des images propres sont très performants, mais restent vulnérables aux attaques adversariales. Cette vulnérabilité apparaît même avec de faibles budgets de perturbation.

Deuxièmement, PGD est systématiquement plus forte que FGSM. Cela confirme que le caractère itératif d'une attaque augmente significativement son efficacité. PGD explore mieux l'espace adversarial autour de l'image originale grâce à la répétition des étapes de gradient et à la projection dans la boule de perturbation autorisée.

Troisièmement, l'entraînement adversarial PGD fonctionne très bien sur MNIST. Le modèle défendu garde une précision propre très élevée tout en devenant beaucoup plus robuste contre FGSM et PGD.

Enfin, CIFAR-10 montre un cas plus réaliste et plus difficile. La défense améliore la robustesse contre certaines attaques PGD, mais elle entraîne une baisse de précision propre et reste limitée face aux attaques fortes. Ce résultat illustre le compromis classique :

$$\text{robustesse adversariale} \uparrow \Rightarrow \text{précision naturelle parfois} \downarrow$$

Des méthodes plus avancées, comme TRADES ou AWP, pourraient être étudiées pour améliorer ce compromis dans des travaux futurs.

8.2 Conclusion

Ce projet a permis de valider expérimentalement la vulnérabilité des CNN aux exemples adversariaux et d'évaluer l'entraînement adversarial comme stratégie de défense. Les deux attaques FGSM et PGD dégradent fortement les performances des modèles baseline, avec PGD comme attaque dominante.

La défense par entraînement adversarial PGD est très efficace sur MNIST, avec un gain de robustesse atteignant **+85.44 points** sous PGD à $\epsilon = 0.15$. Sur CIFAR-10, la défense apporte des améliorations partielles, notamment sous PGD à faible et moyen budget de perturbation, mais elle montre également la difficulté de construire des modèles robustes sur des images plus complexes.

Ainsi, l'entraînement adversarial constitue une défense pertinente, mais son efficacité dépend fortement du dataset, de l'architecture, du budget de perturbation et des hyperparamètres d'entraînement.

Code source complet :

<https://colab.research.google.com/drive/1CeORG2gpcNG1RAvY9KV5IwmSLr7Nvj9j>

Références

- [1] Y. LeCun, C. Cortes, C. Burges. *The MNIST Database of Handwritten Digits*.
<http://yann.lecun.com/exdb/mnist/>
- [2] A. Krizhevsky. *Learning Multiple Layers of Features from Tiny Images – CIFAR-10*.
<https://www.cs.toronto.edu/~kriz/cifar.html>
- [3] I. J. Goodfellow, J. Shlens, C. Szegedy. *Explaining and Harnessing Adversarial Examples*, 2015.
- [4] A. Madry, A. Makelov, L. Schmidt, D. Tsipras, A. Vladu. *Towards Deep Learning Models Resistant to Adversarial Attacks*, 2018.
- [5] OpenAI. *ChatGPT*, assistant IA utilisé lors de l'implémentation du projet. <https://chatgpt.com/>